

Przestrzenne zróżnicowanie poziomów życia w powiatach małopolskich

Małgorzata Gdowska
Zofia Ekielska

Spis treści

1	Wstęp	1
1.1	Opis zmiennych	2
2	Eksploracyjna analiza danych	3
2.1	Wartości brakujące	3
2.2	Podstawowe statystyki opisowe	3
2.3	Histogramy	4
2.4	Zmienne odstające	5
2.5	Korelacje pomiędzy zmiennymi	7
2.6	Zmienność	7
3	Metoda Hellwiga	8
3.1	Przygotowanie zmiennych	8
3.2	Utworzenie wzorca i określenie odległości	9
3.3	Utworzenie antywzorca i określenie odległości	9
3.4	Wyznaczenie wartości miary dla każdego obiektu oraz finalny ranking	10
4	Metoda standaryzowanych sum	11
4.1	Przygotowanie zmiennych	11
4.2	Miara syntetyczna	11
4.3	Ponowna standaryzacja oraz finalny ranking	12
5	Porównanie metod porządkowania liniowego	13
5.1	Korelacja	13
5.2	Grupowanie powiatów według średniej	13
5.3	Ocena rankingów	14
6	Grupowanie podziałowe	15

6.1	Optymalna liczba grup	15
6.2	Grupowanie metodą k-medoid	15
7	Grupowanie hierarchiczne	18
7.1	Wybór zmiennych i standaryzacja	18
7.2	Grupowanie hierarchiczne metodą Warda - dendogram	19
7.3	Indeks Calińskiego i Hrabasza	20
7.4	Podział na 3 klastry	21
7.5	Podział na 4 klastry	22
7.6	Porównanie wyników grupowania	23
8	Podsumowanie	24

1 Wstęp

Małopolska to region, który cechuje wiele tradycji i bogata historia. Jest to miejsce, które zawiera wiele skarbów światowego dziedzictwa UNESCO takie jak: historyczne centrum Krakowa - stolicy województwa, kopalnia soli w Wieliczce i Bochni, czy liczne gotyckie drewniane kościoły. Warto również wspomnieć o licznych atutach przyrodniczych - Tatry, Pieniny, Ojcowski Park Narodowy. Ta różnorodność pozostawia otwartą odpowiedź na pytanie: który powiat charakteryzuje się najwyższym poziomem życia. I chociaż stolica województwa naturalnie buduje swoją przewagę w rankingu, warto sprawdzić, czy rzeczywiście powiat w którym się znajduje rzeczywiście zyska miano "tego najlepszego".

Dlatego właśnie w tej pracy porównamy powiaty Małopolski wielowymiarowo: uwzględnimy warunki środowiskowe i infrastrukturę (zielen, kanalizację, mieszkania, ścieżki rowerowe), dostęp do usług publicznych (lekarzy, kulturę, pomoc społeczną, edukację), aktywność gospodarczą (podmioty REGON) oraz sytuację na rynku pracy i zdrowie publiczne (bezrobocie, długotrwałe bezrobocie, zgony). W tym celu skorzystamy z metod porządkowania liniowego: metody Hellwiga oraz metody standaryzowanych sum.

W efekcie otrzymamy ranking powiatów oraz czytelną mapę zróżnicowań przestrzennych. To pozwoli nam zweryfikować, na ile przewaga stolicy województwa wynika z realnych przewag w wielu obszarach, a gdzie i dlaczego inne powiaty – korzystające z atutów przyrodniczych, uzdrowiskowych czy dziedzictwa kulturowego – mogą konkurować o miano miejsca o najwyższym poziomie życia.

Następnie dzięki analizie skupień odpowiemy na pytanie – jak można pogrupować powiaty Małopolski, żeby uzyskać interpretowalny podział na grupy. Dzięki temu w obrazowy sposób będzie można spojrzeć na strukturę Małopolski i lepiej zrozumieć jej budowę.

1.1 Opis zmiennych

Zmienna	Opis
Zielen	parki, zieleńce i tereny zieleni osiedlowej na 1 mieszkańca (w m2)
Bezrobocie_dluogo	udział bezrobotnych pozostających bez pracy dłużej niż rok (w %)
Bezrobocie	bezrobotni na 1 ofertę pracy
Regon	podmioty wpisane do rejestru REGON na 10 tys. ludności
Uczniowie	uczniowie na 1 pomieszczenie szkolne w szkołach podstawowych
Kultura	uczestnicy imprez kulturalnych na 1000 ludności
Lekarze	lekarze na 10 tys. ludności
Pomoc_spol	miejsca w placówkach stacjonarnej pomocy społecznej na 10 tys. ludności
Kanalizacja	ludność korzystająca z sieci kanalizacyjnej (% ludności ogółem)
Mieszkania	mieszkania oddane do użytku na 1000 zawartych małżeństw
Sciezki_row	ścieżki rowerowe na 10 tys. ludności (w km)
Zgony	zgony niemowląt na 1000 urodzeń żywych

Tabela 1: *Opis zmiennych użytych w analizie*

Wszystkie analizowane zmienne dotyczą roku 2023.

2 Eksploracyjna analiza danych

2.1 Wartości brakujące

W danych występują trzy brakujące wartości w zmiennej Zgony. Nie zdecydowaliśmy się na usunięcie tych rekordów, ponieważ w przypadku porządkowania liniowego oraz analizy skupień ważne jest, żeby uwzględnić wszystkie powiaty. Z tego powodu brakujące wartości zmiennej zostały zastąpione przez jej medianę.

2.2 Podstawowe statystyki opisowe

	Min	Q1	Mediana	Średnia	Q3	Max	Skośność	Kurtoza
Zielen	8.03	24.16	62.44	179.94	101.81	2092.82	4.06	18.25
Bezrobocie_dluogo	0.20	0.52	0.65	0.68	0.80	1.40	0.65	3.52
Bezrobocie	5.18	8.62	13.00	15.29	19.57	39.70	1.04	3.92
Regon	1247.50	1738.97	1965.50	2056.70	2230.93	3590.60	1.34	4.95
Uczniowie	14.00	15.25	16.00	16.23	17.00	19.00	0.31	3.04
Kultura	11580.00	70881.25	126313.00	172844.86	173443.50	1151583.00	3.55	15.56
Lekarze	10.70	20.12	25.35	33.16	35.18	123.00	2.53	9.33
Pomoc_spol	17.10	27.45	32.70	36.06	43.12	79.10	1.25	4.92
Kanalizacja	28.64	46.69	59.42	58.41	65.14	92.69	0.46	2.94
Mieszkania	690.00	871.75	1121.50	1188.50	1320.25	2621.00	1.62	5.57
Sciezki_row	0.49	2.01	3.37	3.58	5.26	7.46	0.17	2.02
Zgony	1.20	2.30	2.91	2.95	3.28	5.21	0.41	2.91

Tabela 2: Podstawowe statystyki opisowe dla zmiennych ilościowych


Większość zmiennych charakteryzuje się dość sporym zróżnicowaniem między powiatami. Patrząc na minimum, maksimum oraz kwartyle, można zauważyć, że rozpiętość danych jest duża – np. dla terenów zielonych czy uczestników imprez kulturalnych.

Średnia i mediana często różnią się między sobą, wskazuje to na asymetrię rozkładów – w tym przypadku prawostronną. Potwierdzają to wysokie wartości skośności, zwłaszcza dla zmiennych takich jak Zielen, Kultura oraz Lekarze. Oznacza to, że przeważają powiaty o niskich wartościach danej cechy, ale pojedyncze jednostki osiągają zdecydowanie wyższe wyniki. Zmienne te charakteryzuje również duża kurtoza - rozkład ma bardziej „spiczasty” kształt w porównaniu z rozkładem normalnym.

Zmienne takie jak Uczniowie, Zgony czy Kanalizacja mają niewielką skośność i kurtozę bliską 3, co wskazuje na rozkład zbliżony do normalnego i mniejsze zróżnicowanie wartości.

Podsumowując, większość analizowanych zmiennych charakteryzuje się prawostronną asymetrią i zróżnicowaniem wartości pomiędzy powiatami.

2.3 Histogramy




Rysunek 1: *Histogramy rozkładu zmiennych ilościowych*

Histogramy potwierdzają wcześniejsze wnioski ze statystyk opisowych. Widać, że większość zmiennych ma prawostronnie skośny rozkład. Najbardziej widoczne jest to dla zmiennych Zielen, Kultura, Mieszkania, Region i Lekarze, gdzie pojawiają się pojedyncze powiaty z wyjątkowo dużymi wartościami. Z kolei Uczniowie, Kanalizacja, Sieczki_row i Zgony mają rozkłady bardziej symetryczne. Pozostałe zmienne, czyli Bezrobocie, Bezrobocie_dluho i Pomoc_spol, mają lekką asymetrię, ale bez dużych odchyłeń.

2.4 Zmienne odstające

Wykresy pudełkowe z wartościami odstającymi



Rysunek 2: Wykresy pudełkowe z wartościami odstającymi


Wykresy pudełkowe wskazują na obecność wartości odstających w kilku zmiennych: Zielen, Kultura, Regon, Lekarze i Mieszkania. Pojedyncze powiaty osiągają tam znacznie wyższe wartości niż pozostałe, co potwierdza wcześniejsze wnioski dotyczące prawostronnej asymetrii rozkładów. Dla zmiennych takich jak Uczniowie, Kanalizacja i Sieczki_row nie ma widocznych wartości odstających, co potwierdza ich bardziej stabilny i symetryczny charakter.

Powiat	Zmienna	Wartość	Typ
Powiat chrzanowski	Zielen	227.92	górna
Powiat nowosądecki	Zielen	407.03	górna
Powiat m. Kraków	Zielen	2092.82	górna
Powiat dąbrowski	Bezrobocie_dluogo	1.40	górna
Powiat tatrzański	Bezrobocie	39.70	górna
Powiat tatrzański	Regon	3233.00	górna
Powiat m. Kraków	Regon	3590.60	górna
Powiat m. Kraków	Kultura	1151583.00	górna
Powiat m. Kraków	Lekarze	123.00	górna
Powiat m. Tarnów	Lekarze	78.00	górna
Powiat miechowski	Pomoc_spol	79.10	górna
Powiat wielicki	Mieszkania	2621.00	górna
Powiat m. Kraków	Mieszkania	2065.00	górna
Powiat nowosądecki	Zgony	5.21	górna
Powiat oświęcimski	Zgony	4.86	górna

Tabela 3: Powiaty z wartościami odstającymi dla poszczególnych zmiennych

Najwięcej wartości odstających występuje w powiecie m. Kraków (aż dla kilku zmiennych, m.in. Kultura, Regon, Lekarze i Mieszkania), co nie jest zaskoczeniem, ponieważ jest to mocno rozwinięte miasto. Odstające wartości pojawiają się też m.in. w powiatach nowosądeckim, tatrzańskim i chrzanowskim. Występują tylko odchylenia górne, czyli powiaty, które mają niestandardowo wysokie wartości. Wartości te nie zostały usunięte, ponieważ każdy powiat stanowi dla nas istotną jednostkę analizy.

2.5 Korelacje pomiędzy zmiennymi



Rysunek 3: Macierz korelacji zmiennych (Spearman)

Na podstawie macierzy korelacji można stwierdzić, że między większością zmiennych nie występują silne zależności ($|r| < 0,7$), co oznacza brak współliniowości między nimi. Jest to korzystne, ponieważ oznacza, że zmienne wnoszą do analizy odrębne informacje.

Wyższa korelacja pomiędzy Uczniami a Regonem może wynikać z faktu, że w powiatach o większej liczbie podmiotów gospodarczych zazwyczaj obserwuje się również lepiej rozwiniętą infrastrukturę edukacyjną - więcej szkół, większe klasy i ogólnie wyższy poziom urbanizacji. Z kolei zależność między Mieszkaniami a Bezrobociem_dlugo może odzwierciedlać ogólną sytuację gospodarczą regionów - w obszarach o wyższym bezrobociu długotrwałym rozwój budownictwa mieszkaniowego jest zwykle wolniejszy, co powoduje, że mogą być ze sobą skorelowane ujemnie.

2.6 Zmienność

Zmienna	V [%]
Zielen	243.12
Kultura	134.85
Lekarze	74.56
Sciezki_row	56.28
Bezrobocie	56.20
Bezrobocie_dluogo	41.50
Pomoc_spol	39.43
Mieszkania	38.90
Zgony	35.06
Kanalizacja	27.77
Regon	26.08
Uczniowie	7.10

Tabela 5: *Współczynnik zmienności (V) dla badanych zmiennych*

Porządana wartość zmienności wynosi $> 10\%$. Wszystkie nasze zmienne osiągają tę wartość poza zmienną Uczniowie. Mimo wszystko zostawiamy ją, ponieważ obrazuje warunki nauczania w szkołach podstawowych, które stanowią istotny element życia społecznego i mogą mieć wpływ na poziom życia.

3 Metoda Hellwiga

Poniżej przeprowadzona zostanie metoda porządkowania Hellwiga w celu zbudowania rankingu i odpowiedzi na pytanie: które małopolskie powiaty są najlepsze do życia.

3.1 Przygotowanie zmiennych

W pierwszym kroku należy określić które zmienne są stymulantami, które destymulantami oraz czy występują nominanty.

Zmienna	Charakter
Zielen	Stymulanta
Bezrobocie_dlugo	Destymulanta
Bezrobocie	Destymulanta
Regon	Stymulanta
Uczniowie	Stymulanta
Kultura	Stymulanta
Lekarze	Stymulanta
Pomoc_spol	Stymulanta
Kanalizacja	Stymulanta
Mieszkania	Stymulanta
Sciezki_row	Stymulanta
Zgony	Destymulanta

Tabela 4: *Charakter zmiennych*

Destymulanty można łatwo zamienić na stymulanty, mnożąc je przez -1. Tak otrzymane wartości zostały zestandaryzowane:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

3.2 Utworzenie wzorca i określenie odległości

W następnym kroku został utworzony “wzorzec”. Zostało to wykonane poprzez znalezienie maksymalnej wartości dla każdej zmiennej:

$$d_j^+ = \max_{i=1,\dots,n} z_{ij}$$

Następnie dla każdego powiatu została policzona odległość od najlepszego obiektu ze wzoru:

$$d_i = \sqrt{\sum_j (z_{ij} - d_j^+)^2}$$

3.3 Utworzenie antywzorca i określenie odległości

Dalej, stosując analogiczną logikę, powstał “antywzorzec”, czyli wektor najniższych wartości dla każdej zmiennej.

Dzięki temu jesteśmy w stanie obliczyć “możliwie daleką odległość”:

$$d_0 = \sqrt{\sum_j (d_j^- - d_j^+)^2}$$

gdzie:

- d_j^- – „najgorsza” wartość j -tej zmiennej (wartość z antywzorca),
- d_j^+ – „najlepsza” wartość j -tej zmiennej (wartość ze wzorca).

3.4 Wyznaczenie wartości miary dla każdego obiektu oraz finalny ranking

Aby wyznaczyć ostateczną wartość miary dla każdego obiektu, która będzie decydowała o miejscu w rankingu, został zastosowany wzór:

$$s_i = 1 - \frac{d_i}{d_0}$$

Rank	Powiat	s_i
1	Powiat m. Kraków	0.7120
2	Powiat m. Nowy Sącz	0.4391
3	Powiat m. Tarnów	0.4341
4	Powiat myślenicki	0.3386
5	Powiat wielicki	0.3333
6	Powiat krakowski	0.3259
7	Powiat bocheński	0.3204
8	Powiat chrzanowski	0.3097
9	Powiat oświęcimski	0.3007
10	Powiat tatrzański	0.2975
11	Powiat olkuski	0.2929
12	Powiat wadowicki	0.2901
13	Powiat brzeski	0.2779
14	Powiat nowotarski	0.2718
15	Powiat miechowski	0.2606
16	Powiat suski	0.2298
17	Powiat gorlicki	0.2260
18	Powiat proszowicki	0.2223
19	Powiat tarnowski	0.2199
20	Powiat nowosądecki	0.2020
21	Powiat limanowski	0.1991
22	Powiat dąbrowski	0.1324

Tabela 5: *Ranking powiatów metodą Hellwiga*

Ranking pokazuje, że powiat miasta Kraków charakteryzuje się najwyższym poziomem życia. Tak jak zostało to ujęte we wstępie – taki wynik nie jest dużym zaskoczeniem, ze względu na to, że jest to stolica małopolski, a także największe, najbardziej zaludnione miasto w tym rejonie. Duże miasto przyciąga inwestorów, ma większy budżet, co oczywiście przyczynia się do polepszenia warunków życia.

Następne powiaty wypadają znacznie gorzej pod względem wyniku. Różnica dzieląca pierwsze i drugie/trzecie miejsce wynosi prawie 0.3 (powiaty osiągają wynik od 0 do 1, więc różnica jest znaczna). Powiatami na wspomnianym drugim i trzecim miejscu są odpowiednio: powiat miasta Nowy Sącz (drugie największe miasto) oraz powiatu miasta Tarnów (trzecie największe miasto).

Na dalszych pozycjach rankingu, powiaty takie jak tatrzański, wadowicki, brzeski czy nowotarski również prezentują przyzwoity poziom życia, jednak ich wyniki wskazują na wyraźne zróżnicowanie w dostępie do usług publicznych, edukacji oraz infrastruktury. W przypadku tych powiatów istotną rolę odgrywa ich specyfika turystyczna, co wpływa na ich dynamikę rozwoju.

Na końcu rankingu znajdują się powiaty takie jak limanowski, nowosądecki i dąbrowski, które uzyskały najniższe wyniki. Ich niższa pozycja może wynikać z trudniejszych warunków gospodarczych, wyższego poziomu bezrobocia, mniejszego dostępu do usług publicznych oraz ogólnie słabszej infrastruktury. W przypadku tych powiatów kluczowe będzie zwiększenie inwestycji w infrastrukturę, rozwój sektora usługowego oraz aktywizację rynku pracy, aby poprawić warunki życia i zniwelować dystans do lepiej rozwiniętych regionów.

Podsumowując, ranking pokazuje wyraźną przewagę dużych miast, zwłaszcza Krakowa, nad resztą regionów Małopolski, a różnice między powiatami wynikają głównie z dostępu do usług, infrastruktury i aktywności gospodarczej.

4 Metoda standaryzowanych sum

Metoda standaryzowanych sum, w przeciwieństwie do metody Hellwiga, jest metodą bezwzorcową - nie wymaga wyznaczania wzorca ani antywzorca. Porównanie jednostek opiera się na uśrednieniu zestandaryzowanych wartości ich cech.

4.1 Przygotowanie zmiennych

W pierwszym kroku analogicznie zmienne o charakterze destymulant zostały pomnożone przez -1 . Następnie również zostały zestandaryzowane.

4.2 Miara syntetyczna

Dla każdej jednostki obliczono miarę syntetyczną jako średnią arytmetyczną z zestandaryzowanych cech:

$$s_i = \frac{1}{m} \sum_{j=1}^m z_{ij},$$

gdzie m to liczba zmiennych.

4.3 Ponowna standaryzacja oraz finalny ranking

W kolejnym etapie dokonano standaryzacji wartości uzyskanych w poprzednim kroku, czyli przekształcenia miary syntetycznej s_i do przedziału $[0, 1]$. W tym celu zastosowano przekształcenie typu *min–max* określone wzorem:

$$s2_i = \frac{s_i - \min(s_i)}{\max(s_i) - \min(s_i)}.$$

Dzięki temu najlepszy obiekt przyjmuje wartość 1, a najslabszy 0.

Następnie powiaty zostały posortowane malejąco względem wartości $s2_i$, dzięki czemu uzyskujemy końcowy ranking.

Rank	Powiat	s2_i
1	Powiat m. Kraków	1.0000
2	Powiat m. Tarnów	0.5781
3	Powiat m. Nowy Sącz	0.5244
4	Powiat wielicki	0.4004
5	Powiat bocheński	0.3394
6	Powiat myślenicki	0.3336
7	Powiat krakowski	0.3111
8	Powiat chrzanowski	0.3090
9	Powiat tatrzański	0.2756
10	Powiat wadowicki	0.2495
11	Powiat oświęcimski	0.2439
12	Powiat brzeski	0.2386
13	Powiat nowotarski	0.2319
14	Powiat miechowski	0.2270
15	Powiat olkusi	0.2159
16	Powiat suski	0.1538
17	Powiat gorlicki	0.1475
18	Powiat tarnowski	0.1334
19	Powiat proszowicki	0.1268
20	Powiat limanowski	0.0717
21	Powiat nowosądecki	0.0492
22	Powiat dąbrowski	0.0000

Tabela 6: *Ranking powiatów metodą standaryzowanych sum*

Na podstawie metody standaryzowanych sum widać, że najwyższy wynik uzyskał **powiat m. Kraków** ($s2_i = 1,0000$), co nie jest zaskoczeniem, bo jako stolica małopolski ma najlepiej rozwiniętą infrastrukturę, najwięcej usług i największe możliwości zatrudnienia. Wysoko w rankingu znalazły się też **powiaty miejskie Tarnów i Nowy Sącz**, które również oferują stosunkowo dobre warunki życia.

Niższe, ale wciąż dobre wyniki osiągnęły **powiaty wielicki, bocheński i myślenicki**, co może wy-

nikać z ich położenia blisko dużych miast i rosnącej atrakcyjności mieszkaniowej.

Z kolei na końcu rankingu znalazły się **powiaty nowosądecki i dąbrowski**, które uzyskały najniższe wartości wskaźnika, co może świadczyć o mniejszym poziomie rozwoju gospodarczego.

Ogólnie wyniki pokazują, że w Małopolsce występują duże różnice między miastami a terenami bardziej wiejskimi – im bliżej centrum regionu, tym lepsze warunki życia.

5 Porównanie metod porządkowania liniowego

5.1 Korelacja

Aby obliczyć korelację między wynikami rankingu powstałego z metody Hellwiga i metody standaryzowanych sum, skorzystałyśmy z korelacji Spearmana. Nie mamy pewności co do rozkładu normalnego wartości z rankingu. Prawdopodobnie metoda Hellwiga nie będzie miała rozkładu normalnego, ponieważ ma dużą wartość odstającą (Kraków) i mocną skośność lewostronną. W związku z tym skorzystamy z korelacji Spearmana, która nie wymaga normalności rozkładu.

Wynik korelacji 0.975 wskazuje na bardzo silną dodatnią korelację między wynikami uzyskanymi metodą Hellwiga a wynikami uzyskanymi metodą standaryzowanych sum. Taka korelacja oznacza, że wyniki w obu metodach są praktycznie identyczne. Powiaty, które zajmują wysokie miejsca w jednym rankingu, zajmują również wysokie miejsca w drugim rankingu.

5.2 Grupowanie powiatów według średniej

Aby pogrupować powiaty w zależności od wyników metod Hellwiga i standaryzowanych sum, zastosowaliśmy grupowanie według średniej. Powiaty zostały podzielone na dwie grupy na podstawie tego, czy ich wynik jest większy lub równy średniej, czy też mniejszy od średniej.

Podział na grupy:

- Grupa „wysoka jakość”: powiaty, których wyniki są większe lub równe średniej.
- Grupa „niska jakość”: powiaty, których wyniki są mniejsze od średniej.

Na podstawie średnich wyników dla obu metod grupowanie powiatów wygląda następująco:

- Grupa “Wysoka jakość”: 8 powiatów, których wyniki były wyższe lub równe średniej.
- Grupa “Niska jakość”: 14 powiatów, których wyniki były poniżej średniej.

Taki sposób grupowania pozwala na szybkie przypisanie powiatów do kategorii na podstawie ich wyników i porównanie powiatów, które osiągnęły wyniki powyżej średniej, z tymi, które znalazły się poniżej średniej.

5.3 Ocena rankingów

Na podstawie przeprowadzonych analiz za pomocą dwóch metod porządkowania liniowego, tj. metody Hellwiga i metody standaryzowanych sum widać, że w obu metodach powiat m. Kraków zajmuje pierwszą pozycję, co nie jest zaskoczeniem, biorąc pod uwagę jego centralną rolę w regionie. Powiaty miejskie, takie jak Tarnów i Nowy Sącz, również osiągnęły wysokie miejsca w obu rankingach, co wskazuje na ich dobrą jakość życia. Jak zostało to pokazane wcześniej, korelacja jest bliska 1, dlatego rankingi są dosyć podobne.


Mimo tej ogólnej zgodności rankingów, powiaty z niższym poziomem życia (np. dąbrowski, limanowski) mogą być klasyfikowane nieco inaczej, ale wciąż znajdują się na końcu listy w obu przypadkach.

Podsumowując, obie metody porządkowania liniowego dostarczyły zbliżone wyniki, a wybrane przez nas powiaty o najlepszych warunkach życia pozostają stabilne w rankingu.

6 Grupowanie podziałowe

W przypadku grupowania podziałowego zdecydowaliśmy się zastosować metodę k-medoid zamiast k-średnich, ponieważ jest ona mniej wrażliwa na wartości odstające (np. powiat m. Kraków ma odstające wartości dla kilku zmiennych nawet po standaryzacji). W metodzie k-medoid centrum klastra stanowi rzeczywisty punkt danych, a nie średnia, dzięki czemu pojedyncze skrajne obserwacje nie zniekształcają wyników grupowania.

6.1 Optymalna liczba grup



Rysunek 4: Porównanie metod łokcia i profilu


Liczbę grup wybrałyśmy na podstawie metody łokcia oraz metody profilu. Oba wykresy wskazują optymalną liczbę klastrów jako 3. W metodzie łokcia po trzech klastrach krzywa spłaszcza się, a w metodzie sylwetki wartość współczynnika osiąga maksimum dla $k = 3$. Oznacza to, że podział na trzy grupy powinien zapewnić najlepszy kompromis między zróżnicowaniem wewnętrznym a odległością między klastrami.

6.2 Grupowanie metodą k-medoid

Metoda k-medoid polega na podziale zbioru obiektów na k grup w taki sposób, aby odległość między obiektami w obrębie jednej grupy była jak najmniejsza. Centra grup (medoidy) są rzeczywistymi obiektami z danych, a klastry tworzą się wokół tych punktów.

Zdecydowaliśmy się zastosować metrykę Manhattan, ponieważ jest bardziej odporna na wpływ

wartości odstających niż metryka euklidesowa. Nie podnosi różnic między obserwacjami do kwadratu więc pojedyncze skrajne wartości nie zniekształcają wyniku grupowania.



Rysunek 5: Wizualizacja klastrow metodą k-medoid

Przed interpretacją wykresu sprawdzamy jeszcze jak prezentują się statystyki w grupach. Zostały wybrane średnie i odchylenia standardowe. Średnie pozwalają zobaczyć czy dana cecha jest w klastrze wyższa albo niższa od przeciętnej (przez to, że dane zostały zestandaryzowane odnoszą się do zera), a odchylenia w nawiasach pokazują, jak bardzo wartości różnią się między powiatami w grupach.

Zmienna	Klaster 1	Klaster 2	Klaster 3
Bezrobocie	-0.18 (1.12)	0.38 (0.72)	-1.18
Bezrobocie_dlugo	-0.39 (0.63)	0.71 (0.95)	-1.70
Kanalizacja	0.44 (0.69)	-0.82 (0.59)	2.11
Kultura	-0.11 (0.30)	-0.32 (0.41)	4.20
Lekarze	0.01 (0.69)	-0.42 (0.35)	3.63
Mieszkania	0.34 (1.00)	-0.66 (0.37)	1.90
Pomoc_spol	-0.07 (0.78)	0.09 (1.33)	0.07
Regon	0.30 (0.70)	-0.72 (0.45)	2.86
Sciezki_row	-0.04 (1.04)	0.04 (1.07)	0.19
Uczniowie	0.45 (0.84)	-0.78 (0.61)	1.54
Zgony	-0.03 (0.94)	0.01 (1.18)	0.34
Zielen	-0.17 (0.14)	-0.26 (0.29)	4.37

Tabela 7: Średnie i odchylenia standardowe zmiennych w poszczególnych klastrach

Pierwsza grupa (Klaster 1) obejmuje powiaty o średnich zbliżonych do przeciętnych wartości zmiennych. W jej skład wchodzi m.in powiaty: krakowski, wielicki, myślenicki, oświęcimski, chrzanowski, wadowicki, bocheński, m. Tranów, m. Nowy Sącz. Leży ona w centrum wykresu, co może nam mówić o umiarkowanym poziomie rozwoju. Jednostki te mają wyższe wartości dla zmiennych Mieszkania, Uczniowie i Kanalizacja. Może to sugerować, że prawdopodobnie mają one lepszą infrastrukturę.

Druga grupa (Klaster 2) to powiaty słabiej rozwinięte, w których większość zmiennych przyjmuje wartości poniżej zera, a nawet bliskie -1 (np. Kanalizacja, Bezrobocie_długo, Regon, Uczniowie). Oznacza to, że powiaty osiągają wyniki gorsze od średniej dla województwa. Na wykresie klaster ten znajduje się po lewej stronie, co potwierdza niższy poziom analizowanych wskaźników. Obejmuje powiaty takie jak: gorlicki, tarnowski, limanowski, nowosądecki, dąbrowski, proszowicki, brzeski oraz suski. Są to głównie obszary wiejskie i peryferyjne, które najprawdopodobniej charakteryzują się słabszym dostępem do usług oraz niższym poziomem gospodarczym.

Trzecia grupa (Klaster 3) to jeden obiekt - powiat m. Kraków, odizolowany punkt po prawej stronie wykresu, daleko od reszty. Wskazuje to, że jest to jednostka nietypowa i niepodobna do reszty powiatów. Znacząco przewyższa inne jednostki pod względem większości zmiennych, szczególnie widoczne jest to dla Kultury, Lekarzy oraz Zieleni. Jest to miasto o wysokim poziomie społeczno-gospodarczym oraz rozwiniętej infrastrukturze.

Wartości odchyłeń standardowych w klastrach 1 i 2 mieszczą się głównie w przedziale 0.3–1.1,

co oznacza umiarkowane lub niewielkie zróżnicowanie powiatów w obrębie tych grup. W klastrze 3 zróżnicowanie wewnętrzne nie występuje, co jest intuicyjne, ponieważ zawiera on tylko jedną obserwację.

7 Grupowanie hierarchiczne

7.1 Wybór zmiennych i standaryzacja

Na korelogramie było widać, że korelacja między większością zmiennych nie przekracza $|0.7|$, więc nie ma poważnej współliniowości. Dzięki tej informacji decydujemy się na zachowanie wszystkich zmiennych przy analizie skupień.

Na wcześniejszych wykresach widać jednak, że występują pewne wartości odstające dla niektórych zmiennych. W celu zbadania, czy te dane osiągają ekstremalnie wysokie wartości, przeprowadzamy test Grubbsa na zestandaryzowanych już danych.


	\Zmienna	\Statystyka	\p-value	\Wniosek
G...1	Zielen	4.373	0.00000	Odstająca wartość
U...2	Zielen	0.046	0.00000	Odstająca wartość
G...3	Bezrobocie_dluogo	2.572	0.05696	Brak odstających
U...4	Bezrobocie_dluogo	0.670	0.05696	Brak odstających
G...5	Bezrobocie	2.839	0.01679	Odstająca wartość
U...6	Bezrobocie	0.598	0.01679	Odstająca wartość
G...7	Regon	2.860	0.01515	Odstająca wartość
U...8	Regon	0.592	0.01515	Odstająca wartość
G...9	Uczniowie	2.407	0.10848	Brak odstających
U...10	Uczniowie	0.711	0.10848	Brak odstających
G...11	Kultura	4.199	0.00000	Odstająca wartość
U...12	Kultura	0.120	0.00000	Odstająca wartość
G...13	Lekarze	3.634	0.00005	Odstająca wartość
U...14	Lekarze	0.341	0.00005	Odstająca wartość
G...15	Pomoc_spol	3.027	0.00608	Odstająca wartość
U...16	Pomoc_spol	0.543	0.00608	Odstająca wartość
G...17	Kanalizacja	2.114	0.29189	Brak odstających
U...18	Kanalizacja	0.777	0.29189	Brak odstających
G...19	Mieszkania	3.098	0.00395	Odstająca wartość
U...20	Mieszkania	0.521	0.00395	Odstająca wartość
G...21	Sciezki_row	1.928	0.49906	Brak odstających
U...22	Sciezki_row	0.814	0.49906	Brak odstających
G...23	Zgony	2.190	0.22991	Brak odstających
U...24	Zgony	0.761	0.22991	Brak odstających

Tabela 8: Wyniki testu Grubbsa dla zestandaryzowanych zmiennych

Z testu Grubbsa wynika, że zmienne takie jak: Zielen, Kultura, Lekarze, Mieszkania, Pomoc_spol mają duże zróżnicowanie między powiatami, co oznacza, że będą najbardziej wpływać na podział

na grupy. Decydujemy się na zachowanie wszystkich tych zmiennych. Z drugiej strony Bezrobocie, Uczniowie, Kanalizacja, Sciezki_row, Zgony są bardziej stabilne (brak istotnych odstępów).


7.2 Grupowanie hierarchiczne metodą Warda - dendrogram



Rysunek 6: *Dendrogram*

Na dendrogramie widać, że Kraków bardzo odróżnia się od innych powiatów, na tyle, że może stanowić osobną grupę. Taki podział nie daje jednak dużej ilości nowych informacji, dlatego zdecydowujemy się na większą ilość grup.

7.3 Indeks Calińskiego i Hrabasza



Rysunek 7: Indeks Calińskiego i Hrabasza


Wykres przedstawia wartości indeksu Calińskiego-Hrabasza w zależności od liczby klastrow. Wartość tego wskaźnika informuje o jakości grupowania – im wyższa, tym lepsze dopasowanie modelu (klastry są bardziej spójne wewnątrz i lepiej od siebie odseparowane).

Na wykresie widać bardzo wysoką wartość CH dla dwóch klastrow, co jednak wynika z tego, że w tym podziale Kraków został odizolowany od reszty województwa. Taki wynik, choć daje najwyższy CH, nie ma będzie dobry dla głębszej interpretacji, ponieważ nie odzwierciedla faktycznych podobieństw między większością powiatów.

Dla dalszych wartości liczby klastrow widać gwałtowny spadek indeksu, a następnie jego powolne wypłaszczanie. Na podstawie tego decydujemy się na sprawdzenie tego, jak kształtują się grupy dla 3 i 4 klastrow. Ten podział może być najbardziej adekwatny dla naszego badania. Będzie to kompromis między jakością grupowania a możliwością sensownej interpretacji wyników.

Wzrost wartości CH od 8 grup nie ma większego znaczenia, ponieważ przy tak dużej liczbie klastrow grupy będą dość małe - około 2,3 jednostki, co będzie zbyt szczegółowym podziałem dla naszych danych.


7.4 Podział na 3 klastry



Rysunek 8: *Dendrogram dla 3 klastrów*

Widać, że taki podział dalej rozróżnia tylko Kraków, 2 najlepiej rozwinięte powiaty miast na prawach powiatu i resztę powiatów. Takie rozwiązanie dalej nie daje wielu nowych informacji, dlatego decydujemy się na podział na 4 klastry.

7.5 Podział na 4 klastry



Rysunek 9: Dendrogram dla 4 klastrów

Takie pogrupowanie pozwala już na lepszą interpretację.

Widzimy tutaj cztery grupy:

I Powiat miasta Kraków

Tak jak zostało to pokazane na wcześniejszych dendrogramach, powiat ten mocno odstaje od pozostałych. Można więc wnioskować, że Kraków stanowi oddzielny typ rozwoju - różnica między nim, a pozostałymi częściami Małopolski jest znaczna. Kraków jest silnie zurbanizowany i charakteryzuje się zdecydowanie najwyższym poziomem życia, co zostało już pokazane we wcześniejszych rankingach.

Duże zaludnienie, wiele ośrodków naukowych oraz duża ilość najróżniejszych inwestycji sprawia, że miasto pełni funkcję dominującego ośrodka metropolitalnego regionu. Jest centrum administracyjnym, akademickim i kulturalnym, które przyciąga inwestycje, a także mieszkańców okolicznych powiatów do pracy i edukacji. Wysoki poziom rozwoju infrastruktury, usług publicznych oraz dostępność komunikacyjna wzmacniają jego przewagę nad resztą województwa, co potwierdza, że

Kraków jest rdzeniem rozwoju Małopolski i naturalnym punktem odniesienia dla pozostałych jednostek.

II Powiat miasta Nowy Sącz i Powiat miasta Tarnów

Drugą grupę stanowią podobnie inne duże ośrodki miejskie. Znowu - są to miasta na prawach powiatu. Stanowią one grupę ośrodków o średnim poziomie miejskości w regionie. "Bliżej" im do pozostałych powiatów niż do Krakowa, co pokazuje fakt, że przy podziale na dwie grupy, powiaty nie zostały przydzielone do klastru z Krakowem.

Wyróżniają się one relatywnie dobrze rozwiniętą infrastrukturą techniczną i społeczną, a także stosunkowo wysoką liczbą podmiotów gospodarczych. Jednocześnie obserwuje się w nich umiarkowany poziom bezrobocia oraz dobrą dostępność usług publicznych, co potwierdza ich funkcję regionalnych centrów rozwoju.

III Powiaty: olkuski, wadowicki, krakowski, myślenicki, proszowicki, limanowski, suski, chrzanowski, gorlicki, tatrzański, wielicki

To jednostki, które – mimo że nie dorównują ośrodkom miejskim – osiągają wyższe wartości wskaźników niż grupa III. Część z nich korzysta z efektów sąsiedztwa silniejszych rynków pracy (strefy podmiejskie), inne – z funkcji turystycznych i usługowych (np. zaplecze górskie). W rezultacie łączą one niezły dostęp do infrastruktury z przyzwoitą aktywnością gospodarczą i relatywnie korzystnymi wynikami społecznymi. W hierarchii plasują się powyżej grupy III, stanowiąc „mocniejszy” segment poza dużymi miastami.

IV Powiaty: miechowski, dąbrowski, nowosądecki, oświęcimski, bocheński, nowotarski, brzeski, tarnowski

Tworzą ją jednostki, które w większości mają słabszą dostępność usług publicznych i infrastruktury oraz gorszą sytuację na rynku pracy. To powiaty bardziej oddalone od głównych centrów, gdzie dominuje struktura wiejska i rozproszona zabudowa. Wskazuje to na niższy poziom urbanizacji i mniejsze możliwości dyfuzji rozwoju. W ujęciu hierarchicznym jest to grupa „dalsza” zarówno od Krakowa, jak i od subcentrów, a bliższa dołu rankingu.

7.6 Porównanie wyników grupowania

Dzięki wykonanym powyżej: metodzie k-medoid oraz metodzie grupowania hierarchicznego uzyskaliśmy dwa różne podziały powiatów Małopolski.

Dzięki pierwszej metodzie uzyskaliśmy 3 grupy, natomiast korzystając z drugiej mamy 4 grupy. W obu przypadkach jedną grupę stanowi sam powiat miasta Kraków, co podkreśla jego znaczące zróżnicowanie od innych rozpatrywanych obiektów. Miasta na prawach powiatu także znajdują się razem w drugich grupach. Metoda hierarchiczna podkreśla jednak bardziej ich odrębność od reszty

powiatów, przydzielając je do ich własnej, osobnej grupy. Metoda k-medoid zestawia je w jednej grupie wraz z takimi obiektami jak: powiat wielicki, krakowski, czy wadowicki.

Między grupami III i IV w metodzie hierarchicznej, a grupą 1 i 2 w metodzie k-medoid ciężko dostrzec jednak pewne gruntowne podobieństwa. Widać, że powiaty z “najgorszego” klastra (ten o najniższej średniej wewnątrz grupy) z metody hierarchicznej, w drugiej metodzie widnieją jako te w “średnim” klastrze. Przykładem tego mogą być powiaty: gorlicki, limanowski, proszowicki i suski.

Różnice w wynikach są nieuniknione, ponieważ każda z metod ma inną logikę działania. Metoda k-medoid dąży do stworzenia grup o minimalnej wariancji wewnętrznej. Z kolei grupowanie hierarchiczne buduje drzewiastą strukturę pokrewieństw, która pozwala na bardziej szczegółowe, “zagnieżdżone” podziały. Dlatego też było ono w stanie wyłonić cztery grupy, precyzyjniej oddzielając miasta Tarnów i Nowy Sącz od pozostałych powiatów, a także dzieląc te pozostałe na dwie podgrupy o nieco innym charakterze (bliższe ośrodkom miejskim vs. peryferyjne).

Kluczowy wniosek płynący z tego porównania jest następujący: powiaty, które w jednej metodzie zaliczają się do “słabszych”, w drugiej trafiają do grupy “przeciętnej”, co sugeruje, że nie tworzą one jednorodnej, odrębnej kategorii, lecz raczej stanowią “niższą półkę” w obrębie szerokiej grupy powiatów o średnim poziomie rozwoju. Oba podziały jednoznacznie potwierdzają natomiast dominującą i unikatową pozycję Krakowa oraz istotną, pośrednią rolę innych miast na prawach powiatu w strukturze regionalnej Małopolski.

8 Podsumowanie

Po przeprowadzeniu analizy przy pomocy porządkowania liniowego (Hellwiga i standaryzowanych sum) oraz grupowania (k-medoid i hierarchicznego) widoczne jest zróżnicowanie przestrzenne poziomu życia w powiatach Małopolski. We wszystkich przypadkach powiat miasta Kraków osiągnął najwyższe wyniki. Łatwo więc stwierdzić, że ma on dominującą pozycję gospodarczą, społeczną oraz infrastrukturalną w regionie. Wysoka jakość życia widoczna jest również w innych miastach na prawach powiatu - Tarnowie i Nowym Sączu. Metoda Hellwiga i standaryzowanych sum dały bardzo zbliżone do siebie rankingi. Natomiast w przypadku analiz skupień, szczegóły podziału różnią się ale rozmieszczenie grup na mapie Małopolski jest podobne - te same obszary wypadają jako lepiej lub gorzej rozwinięte. Z pewnością możemy wyodrębnić kluczowy wniosek - w Małopolsce widoczny jest silny kontrast pomiędzy dobrze zurbanizowanym centrum regionu a słabiej rozwiniętymi jednostkami znajdującymi się dalej od “serca” województwa.

Spis rysunków

1	<i>Histogramy rozkładu zmiennych ilościowych</i>	4
2	<i>Wykresy pudełkowe z wartościami odstającymi</i>	5
3	<i>Macierz korelacji zmiennych (Spearman)</i>	7
4	<i>Porównanie metod łokcia i profilu</i>	15
5	<i>Wizualizacja klastrow metodą k-medoid</i>	16
6	<i>Dendogram</i>	19
7	<i>Indeks Calińskiego i Hrabasza</i>	20
8	<i>Dendogram dla 3 klastrow</i>	21
9	<i>Dendogram dla 4 klastrow</i>	22

Spis tabel

1	<i>Opis zmiennych użytych w analizie</i>	2
2	<i>Podstawowe statystyki opisowe dla zmiennych ilościowych</i>	3
3	<i>Powiaty z wartościami odstającymi dla poszczególnych zmiennych</i>	6
5	<i>Współczynnik zmienności (V) dla badanych zmiennych</i>	8
4	<i>Charakter zmiennych</i>	9
5	<i>Ranking powiatów metodą Hellwiga</i>	10
6	<i>Ranking powiatów metodą standaryzowanych sum</i>	12
7	<i>Średnie i odchylenia standardowe zmiennych w poszczególnych klastrach</i>	17
8	<i>Wyniki testu Grubbsa dla zestandaryzowanych zmiennych</i>	18